閃存類存儲的轉換層

上篇「柱面-磁頭-扇區尋址的一些舊事」整理了一下我對磁盤類存儲設備（包括軟盤、硬盤，不包括光盤、磁帶）的一些理解，算是爲以後討論文件系統作鋪墊；這篇整理一下我對閃存類存儲設備的理解。

這裏想要討論的閃存類存儲是指 SSD 、SD卡、U盤等基於 NAND 又有轉換層的存儲設備（下文簡稱閃存盤），但不包括裸 NAND 設備、3D Xpoint （Intel Optane）等相近物理結構但是沒有類似轉換層的存儲設備。閃存類存儲設備這幾年發展迅猛，SD卡和U盤早就

替代軟盤成爲數據交換的主流， SSD 大有替代硬盤的趨勢。 因爲發展迅速，所以其底層技術變革很快，不同於磁盤類存儲技術有很多公開資料可以獲取， 閃存類存儲的技術細節通常是廠商們的祕密，互聯網上能找到很多外圍資料， 但是關於其如何運作的細節卻很少提到。所以我想先整理一篇筆記，記下我蒐集到的資料，加上我自己的理解。 本文大部分信息來源是 Optimizing Linux with cheap flash drives 和 A Summary on SSD & FTL ，加上我的理解，文中一些配圖也來自這兩篇文章。

封裝結構

從外部來看，一個閃存盤可能有這樣的結構：

從上往下，我們買到的一個閃存盤可能一層層分級：

1. 整個閃存盤有個控制器，其中含有一部分 RAM 。然後是一組 NAND Flash 封裝芯片（chip）。
2. 每個封裝芯片可能還分多個 Device ，每個 Device 分多個 Die ，這中間有很多術語我無法跟上，大概和本文想討論的事情關係不大。
3. 每個 Die 分多個平面（Plane），平面之間可以並行控制，每個平面相互獨立。從而比如在一個平面內 做某個塊的擦除操作的時候，別的平面可以繼續讀寫而不受影響。
4. 每個平面分成多個段（Segment)，段是擦除操作的基本單位，一次擦除一整個段。
5. 每個段分成多個頁面（Page），頁面是讀寫操作的基本單位，一次可以讀寫一整頁。

6. 頁面內存有多個單元格（Cell），單元格是存儲二進制位的基本單元，對應 SLC/MLC/TLC/QLC 這些， 每個單元格可以存儲多個二進制位。

以上這些名字可能不同廠商不同文檔的稱法都各有不同，隨着容量不斷增大，廠商們又新造出很多抽象層次， 不過這些可能和本文關係不大，如果看別的文檔注意區別術語，本文中我想統一成以上術語。 重要的是有並行訪問單元的平面（Plane）、擦除單元的段（Segment）、讀寫單元的頁（Page）這些概念。 抽象地列舉概念可能沒有實感，順便說一下這些概念的數量級：

1. 每个 SSD 可以有数个封装芯片。
2. 每个芯片有多个 Die 。
3. 每个 Die 有多个平面。
4. 每个平面有幾千個段。比如 2048 個。
5. 每個段有數百個頁，比如 128 個，外加一些元数据。
6. 每個頁面是 4KiB、8KiB 這樣的容量，外加幾百字節的元數據。

和硬盤相比，一個閃存頁面大概對應一個到數個物理扇區大小，現代硬盤也逐漸普及 4KiB 物理扇區。 每次讀寫都可以通過地址映射直接對應到某個閃存頁面，這方面沒有硬盤那樣的尋址開銷。 不過閃存有寫入的限制，每次寫入只能寫在「空」的頁面上，不能覆蓋寫入已有數據的頁面。 要重複利用已經寫過的頁面，需要對頁面所在段整個做擦除操作，每個段是大概 128KiB 到

8MiB 這樣的數量級。每個擦除段需要單獨跟蹤和統計自己經歷的擦除次數，以進行擦寫均衡（wear leveling）。

擦寫均衡（wear leveling）和段映射

Animation: wear leveling on SSD drives

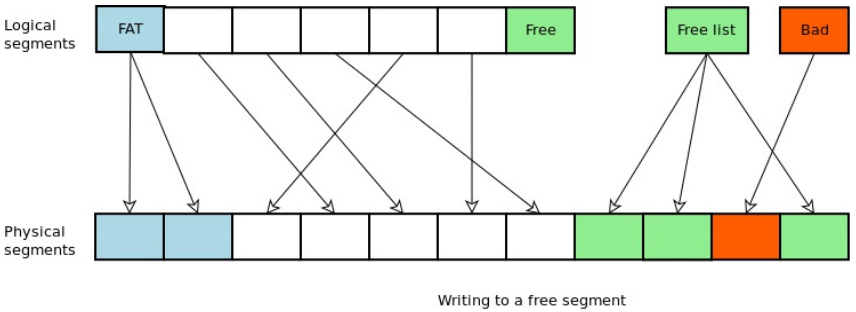

擦除段的容量大小是個折衷，更小的擦除段比如 128KiB 更適合隨機讀寫， 因爲每隨機修改一部分數據時需要垃圾回收的粒度更小；而使用更大的擦除段可以減少元數據和地址映射的開銷。 從擦除段的大小這裏，已經開始有高端閃存和低端閃存的差異，比如商用 SSD 可能比 U 盤和 SD 卡使用更小的擦除段大小。

閃存盤中維護一個邏輯段地址到物理段地址的隱射